

Predykcja cen akcji spółki PZU oraz korelacja z czynnikami gospodarczymi

Analiza i prognozowanie wielowymiarowego szeregu czasowego

Maciej Kuchcik

Andrzej Szuwald

2026-06-14

Spis treści

Inicjalizacja	2
1 Wstęp	4
1.1 Cel	4
1.2 Dane	4
1.2.1 Giełda PZU	4
1.2.2 Wskaźniki makroekonomiczne	5
1.3 Wyznaczenie wspólnego zakresu dat	8
1.4 Podział danych	10
2 Analiza i predykcja	11
2.1 Model naiwny	11
2.2 Model ARIMA	16
2.3 Model VAR	16
2.4 Model MIDASR (A)	16
2.5 Model MIDASR (B)	16
3 Wyniki	17
4 Wnioski i podsumowanie	18
Bibliografia	19
Spis rysunków	20

Inicjalizacja

W tej części ładowane są biblioteki oraz inicjalizowane są zmienne.

Zmienna *FORMAT* jest flagą, która wskazuje jaki silnik został wykorzystany podczas renderowania. Wykorzystane jest to podczas tworzenia wykresów. Język R wtedy decyduje, czy wyrenderować wersję internetową (HTML: grafy interaktywne, zmieniające kolor w zależności od motywu), lub dokumentową (PDF: stałe zdjęcia).

```
if (!require("quantmod")) install.packages("quantmod")
library(quantmod)
library(ggplot2)
if (!require("readxl")) install.packages("readxl")
library(readxl)
if (!require("tseries")) install.packages("tseries")
library(tseries)
if (!require("highcharter")) install.packages("highcharter")
library("highcharter")

options(highcharter.lang = list(
  months = c("Styczeń", "Luty", "Marzec", "Kwiecień", "Maj", "Czerwiec",
             "Lipiec", "Sierpień", "Wrzesień", "Październik",
             "Listopad", "Grudzień"),
  shortMonths = c("Sty", "Lut", "Mar", "Kwi", "Maj", "Cze",
                  "Lip", "Sie", "Wrz", "Paź", "Lis", "Gru"),
  weekdays = c("Niedziela", "Poniedziałek", "Wtorek", "Środa", "Czwartek",
               "Piątek", "Sobota"),
  shortWeekdays = c("Nie", "Pon", "Wto", "Śro", "Czw", "Pią", "Sob"),
  rangeSelectorFrom = "Od",
  rangeSelectorTo = "Do",
  rangeSelectorZoom = "Zakres",
  loading = "Ładowanie..."
)
)

FORMAT<-knitr::pandoc_to()
if (is.null(FORMAT)) {
  FORMAT <- "html"
}

rysuj_rdzen <- function(dane_ts, tytul, etykieta_y, kolory) {
  plot(dane_ts, xlab = "Rok", ylab = etykieta_y,
```

```

    main = tytuł, col = kolory$linia, lwd = 2)
grid(col = kolory$siatka)

start_zagrozenia <- 2020 + (3 - 1) / 12
koniec_zagrozenia <- 2023 + (6 - 1) / 12

rect(start_zagrozenia, par("usr")[3], koniec_zagrozenia, par("usr")[4],
      col = rgb(1, 0, 0, 0.12), border = NA)

legend("topleft", legend = "COVID", fill = rgb(1, 0, 0, 0.12),
       border = NA, bty = "n")
}

rysuj_makro_wykres <- function(dane_ts, tytuł, etykieta_y, format = "pdf") {
  # Zawsze: jasna
  jasne_kolory <- list(linia = "royalblue", siatka = "#cccccc")
  par(bg = "white", col.axis = "black", col.lab = "black",
      col.main = "black", fg = "black")
  rysuj_rdzen(dane_ts, ifelse(format == "html", tytuł, ""),

              etykieta_y, jasne_kolory)

  # HTML: rysujemy też wersję ciemną
  if (format == "html") {
    par(bg = "#222222", col.axis = "#dddddd", col.lab = "#dddddd",
        col.main = "#dddddd", fg = "#dddddd")
    ciemne_kolory <- list(linia = "#6baed6", siatka = "#444444")
    rysuj_rdzen(dane_ts, tytuł, etykieta_y, ciemne_kolory)

    # Reset po HTML
    par(bg = "white", col.axis = "black", col.lab = "black",
        col.main = "black", fg = "black")
  }
}

```

1 Wstęp

1.1 Cel

W tym projekcie porównamy różne metody predykcji akcji giełdowych spółki **PZU** (Powszechny Zakład Ubezpieczeń S.A.) oraz zbadamy wpływ dodania innych zmiennych na jakość danych wyjściowych.

Badanie rozpocznie się od stworzenia modelu naiwnego (bazowego), do którego porównywać się będą inne metryki. Model ten będzie zakładał, że

$$\text{predykowana cena} = \text{cena wczorajsza}$$

Następnie zostaną wykorzystane bardziej złożone funkcje jak *VAR* czy *ARIMAX* (przez *autoarime*), do których później dodatkowo zostaną dołożone kolejne wymiary (np. dane o inflacji, stopie bezrobocia czy PKB) aby zweryfikować wpływ danych makroekonomicznych.

1.2 Dane

Dane giełdowe pobrane zostaną z biblioteki **quantmod** poprzez API Yahoo Finance do GPW (Giełdy Papierów Wartościowych).

1.2.1 Giełda PZU


```
pzu_raw<-getSymbols("PZU.WA", auto.assign = F)

if(FORMAT == "html"){
  p <- highchart(type = "stock")
  p <- hc_title(p, text = "Wykres akcji spółki PZU")
  p <- hc_add_series(p, pzu_raw, name = "Cena")
  p <- hc_navigator(p, enabled = TRUE)
  p <- hc_scrollbar(p, enabled = TRUE)

  p <- hc_yAxis(p,
    min = 0,
    max = max(Cl(pzu_raw))
  )

  p
}else{
  chartSeries(pzu_raw,
```

```
theme = chartTheme("white"), name = "")
}
```



Rysunek 1: Wykres akcji spółki PZU

1.2.2 Wskaźniki makroekonomiczne

Wskaźniki makroekonomiczne zostały pobrane ze strony **GUS** (Główny Urząd Statystyczny) i pliku **Kwartalne wskaźniki makroekonomiczne** lub **Wybrane miesięczne wskaźniki makroekonomiczne** (Główny Urząd Statystyczny (2026)).


- PKB pobrano z danych kwartalnych z arkusza **RACHUNKI NARODOWE**.
- Inflację pobrano z danych miesięcznych z arkusza **WSKAŹNIKI CEN**.
- Procentową stopę bezrobocia pobrano z danych miesięcznych z arkusza **RYNEK PRACY**.

Te dane zostały następnie przerobione ręcznie do pliku **makro.xlsx** do arkuszy o odpowiednich nazwach.

```
pkb_raw <- read_excel("makro.xlsx", sheet = "PKB")

rok<-as.numeric(format( min(as.Date(pkb_raw$DATA)), "%Y"))
kwartal<-(as.numeric(format( min(as.Date(pkb_raw$DATA)), "%m")) - 1) %/% 3 + 1
```

```
pkb_ts <- ts(as.numeric(as.character(pkb_raw$WARTOŚĆ)),
             frequency = 4, start = c(rok, kwartal))
rysuj_makro_wykres(pkb_ts/1000, "Produkt Krajowy Brutto Polski",
                  "Wartość (mln zł)", FORMAT)
```




Rysunek 2: Produkt Krajowy Brutto Polski

```
inflacja_raw <- read_excel("makro.xlsx", sheet = "Inflacja")

rok<-as.numeric(format( min(as.Date(inflacja_raw$DATA)), "%Y"))
miesiac<-as.numeric(format( min(as.Date(inflacja_raw$DATA)),"%m"))

inflacja_ts <- ts(as.numeric(as.character(inflacja_raw$WARTOŚĆ)),
                 frequency = 12, start = c(rok, miesiac))
rysuj_makro_wykres(inflacja_ts - 100, "Inflacja", "Inflacja %", FORMAT)
```




Rysunek 3: Inflacja

```
bezrobocie_raw <- read_excel("makro.xlsx", sheet = "Bezrobocie%")

rok<-as.numeric(format( min(as.Date(bezrobocie_raw$DATA)), "%Y"))
miesiac<-(as.numeric(format( min(as.Date(bezrobocie_raw$DATA)), "%m"))))

bezrobocie_ts <- ts(as.numeric(as.character(bezrobocie_raw$WARTOŚĆ)),
                    frequency = 12, start = c(rok, miesiac))
rysuj_makro_wykres(
  bezrobocie_ts, "Procentowa stopa bezrobocia", "% stopa bezrobocia", FORMAT)
```

Rysunek 4: Procentowa stopa bezrobocia

1.3 Wyznaczenie wspólnego zakresu dat

Należy zbadać, czy wszystkie dane mają tę samą datę początkową i kończą. Jeżeli ich daty się różnią, należy skrócić wszystkie zbiory do największej z dat początkowych oraz najmniejszej z dat końcowych (biorąc pod uwagę różne częstotliwości).

```
zbadaj_daty<-function(data_ts) {
  min_data <- start(data_ts)
  max_data <- end(data_ts)
  freq <- frequency(data_ts)

  freq_name <- switch(as.character(freq),
    "1" = "roczne",
    "4" = "kwartalne",
    "12" = "miesięczne",
    "52" = "tygodniowe",
    "dziennie")

  cat(sprintf(
```

```

    "Szereg czasowy '%s' trwa od %d-%02d do %d-%02d o częstotliwości: %s.",
        deparse(substitute(data_ts)),
        min_data[1], min_data[2],
        max_data[1], max_data[2],
        freq_name), "\n")
}

cat(sprintf(
    "Dane giełdowe PZU obejmują zakres od %s do %s o częstotliwości: dzienne",
    as.character(index(first(pzu_raw))),
    as.character(index(last(pzu_raw)))), "\n")

```

Dane giełdowe PZU obejmują zakres od 2010-05-11 do 2026-06-12 o częstotliwości: dzienne

```
zbadaj_daty(pkb_ts)
```

Szereg czasowy 'pkb_ts' trwa od 2009-01 do 2025-01 o częstotliwości: kwartalne.

```
zbadaj_daty(bezrobocie_ts)
```

Szereg czasowy 'bezrobocie_ts' trwa od 2010-01 do 2026-04 o częstotliwości: miesięczne.

```
zbadaj_daty(inflacja_ts)
```

Szereg czasowy 'inflacja_ts' trwa od 2010-01 do 2026-04 o częstotliwości: miesięczne.

Początki: 2010-05-11, 2009-01, 2010-01, 2010-01.

- Najpóźniejszy start to **2010-05-11**. Ze względu na szereg kwartalny, musimy zaokrąglić to do najbliższego pełnego okresu: **2010-07-01** (początek trzeciego kwartału).

Końce: 2026-06-12, 2025-01, 2026-04, 2026-04.

- Najwcześniejszy koniec to **2025-01**. Ze względu na to, że to szereg kwartalny, możemy brać daty aż do końca tego kwartału: **2025-03-31**.

```
przytnij_dane <- function(data) {  
  start <- as.Date("2010-07-01")  
  end   <- as.Date("2025-03-31")  
  dane_xts <- as.xts(data)  
  index(dane_xts) <- as.Date(index(dane_xts))  
  window(dane_xts, start = start, end = end)  
}  
  
pkb_final      <- przytnij_dane(pkb_ts)  
bezrobocie_final <- przytnij_dane(bezrobocie_ts)  
inflacja_final  <- przytnij_dane(inflacja_ts)  
pzu_final       <- przytnij_dane(pzu_raw)
```

1.4 Podział danych

2 Analiza i predykcja

Ta część projektu zostanie poświęcona ostatecznej prodekcji dziennych cen zamknięcia akcji spółki PZU wykorzystując coraz to bardziej zaawansowane metody, by zweryfikować, które dane i jak najbardziej wpływają na jakość danych wyjściowych. Zostanie zastosowana taka kolejność:

1. **Model naiwny/bazowy:** predykcja = wartość wczorajsza. Wykorzystane zostaną tylko dane z cen zamknięcia (jeden wymiar, jedna częstotliwość).
2. **Model ARIMA:** wykorzystana zostanie *autoarima* na cenach zamknięcia (jeden wymiar, jedna częstotliwość).
3. **Model VAR:** użyje funkcji *VAR* oraz pełnych danych giełdowych z cenami zamknięcia, wolumenem, cenami minimalnymi i maksymalnymi (kilka wymiarów, jedna częstotliwość).
4. **Model MIDASR A:** wykorzysta model *midasr* oraz **cen zamknięcia** akcji wraz z danymi makroekonomicznymi (kilka wymiarów, kilka częstotliwości).
5. **Model MIDASR B:** wykorzysta model *midasr* oraz **pełnych informacji giełdowych** wraz z danymi makroekonomicznymi (kilka wymiarów, kilka częstotliwości).

Dodatkowo modele oparte na funkcji *midasr* rozbite zostały na dwie wersje: A, która korzysta tylko z jednego wymiaru danych giełdowych oraz B, który wykorzystuje je wszystkie. Pozwoli to dokładniej zbadać wartość dodaną innych wymiarów danych giełdowych na jakość wyników predykcji modelu.

2.1 Model naiwny

Jak opisano we [wstępie](#), model naiwny (czy też bazowy) będzie zakładał, że

$$\text{predykowana cena} = \text{cena wczorajsza}$$

Będzie to model jednowymiarowy, korzystający tylko z cen zamknięcia i posłuży jako baseline (wartość porównawcza) do predykcji z innych modeli.

Dane zostają podzielone chronologicznie na trzy rozłączne zbiory:

- **Treningowy (70%)** - estymacja modeli,
- **Walidacyjny (20%)** - strojenie i porównanie modeli,
- **Testowy (10%)** - ostateczna ocena jakości predykcji.

```
pzu_close <- Cl(pzu_final)
n <- nrow(pzu_close)

n_train <- floor(0.70 * n)
n_val   <- floor(0.20 * n)
n_test  <- n - n_train - n_val
```

```

pzu_train <- pzu_close[1:n_train, ]
pzu_val   <- pzu_close[(n_train + 1):(n_train + n_val), ]
pzu_test  <- pzu_close[(n_train + n_val + 1):n, ]

cat(sprintf(
  "Liczba obserwacji: %d
  Treningowy   (70%): %d   (%s - %s)
  Walidacyjny (20%): %d   (%s - %s)
  Testowy      (10%): %d   (%s - %s)\n",
  n,
  nrow(pzu_train), as.character(index(first(pzu_train))),
  as.character(index(last(pzu_train))),
  nrow(pzu_val),   as.character(index(first(pzu_val))),
  as.character(index(last(pzu_val))),
  nrow(pzu_test),  as.character(index(first(pzu_test))),
  as.character(index(last(pzu_test)))
))

```

```

Liczba obserwacji: 3786
  Treningowy   (70%): 2650   (2010-07-01 - 2020-09-16)
  Walidacyjny (20%): 757    (2020-09-17 - 2023-09-21)
  Testowy      (10%): 379    (2023-09-22 - 2025-03-31)

```

```

pzu_test_pred<-lag(pzu_close, k = 1)[(n_train + n_val + 1):n, ]
pzu_test_real<-pzu_test
e<-as.numeric(pzu_test_real) - as.numeric(pzu_test_pred)

metryki_naiwny <- c(
  MAE  = mean(abs(e)),
  RMSE = sqrt(mean(e^2)),
  MAPE = mean(abs(e / as.numeric(pzu_test_real))) * 100
)

if (FORMAT == "html") {
  # Wykres interaktywny HTML

  df_naiwny <- data.frame(
    data          = index(pzu_test_real),
    rzeczywiste   = as.numeric(pzu_test_real),
    predykcja     = as.numeric(pzu_test_pred),
    blad          = e
  )
}

```

```

)

highchart() |>
  hc_title(text = "Model naiwny - predykcja vs rzeczywistość (zbiór testowy)") |>
  hc_xAxis(type = "datetime") |>
  hc_yAxis_multiples(
    list(title = list(text = "Cena zamknięcia (zł)", opposite = FALSE,
      min = 37, max = 60, startOnTick = FALSE, endOnTick = FALSE),
    list(title = list(text = "Błąd (zł)", opposite = TRUE, gridLineWidth = 0,
      min = -10, max = 4, startOnTick = FALSE, endOnTick = FALSE)
  ) |>

  hc_add_series(
    data = list_parse2(data.frame(
      x = as.numeric(as.POSIXct(df_naiwny$data)) * 1000,
      y = df_naiwny$rzeczywiste
    )),
    type = "line", name = "Rzeczywista", color = "#2196F3", yAxis = 0
  ) |>

  hc_add_series(
    data = list_parse2(data.frame(
      x = as.numeric(as.POSIXct(df_naiwny$data)) * 1000,
      y = df_naiwny$predykcja
    )),
    type = "line", name = "Predykcja (naiwna)", color = "#FF9800",
    dashStyle = "ShortDash", yAxis = 0
  ) |>

  hc_add_series(
    data = list_parse2(data.frame(
      x = as.numeric(as.POSIXct(df_naiwny$data)) * 1000,
      y = df_naiwny$blad
    )),
    type = "line", name = "Błąd", color = "rgba(229, 57, 53, 0.5)",
    dashStyle = "Solid", yAxis = 1
  ) |>

  hc_tooltip(valueDecimals = 2, valueSuffix = " zł", shared = TRUE) |>
  hc_legend(enabled = TRUE) |>
  hc_rangeSelector(enabled = TRUE) |>
  hc_scrollbar(enabled = TRUE)

```

```

} else {
  # wykres statyczny dla PDF

  blad <- e
  daty <- index(pzu_test_real)

  par(bg = "white", col.axis = "black",
      col.lab = "black", col.main = "black", fg = "black"
  )
  plot(daty, as.numeric(pzu_test_real),
      type = "l", col = "royalblue", lwd = 2,
      xlab = "Data", ylab = "Cena zamknięcia (zł)"
  )
  lines(daty, as.numeric(pzu_test_pred),
      col = "tomato", lwd = 2, lty = 2
  )
  grid(col = "#cccccc")


  # oś Y dla błędu
  par(new = TRUE)
  plot(daty, blad,
      type = "l", col = adjustcolor("red3", alpha.f = 0.5),
      lwd = 1.5, lty = 1,
      axes = FALSE, xlab = "", ylab = ""
  )
  axis(4, col = "red3", col.axis = "red3")
  mtext("Błąd (zł)", side = 4, line = 3, col = "red3")

  legend("topleft",
      legend = c("Rzeczywista", "Predykcja (naiwna)", "Błąd"),
      col = c("royalblue", "tomato", "red3"),
      lty = c(1, 2, 1), lwd = 2, bty = "n")
}

```

metryki_naiwny

MAE	RMSE	MAPE
0.5916094	0.8521147	1.2467112



Rysunek 5: Model naiwny - predykcja vs rzeczywistość (zbiór testowy)

Metryki:

- $MAE = 0.59$ zł - średnio model myli się o niecałe 60 groszy,
- $RMSE = 0.85$ zł - większy od MAE, zdarzają się pojedyncze dni z większymi skokami (RMSE karze mocniej za duże błędy),
- $MAPE = 1.25\%$ - procentowo błąd jest bardzo mały. Przy cenie akcji z zakresu 40–60 zł pomyłka o 1.25% to właśnie około 60 groszy.

Wykres:

Linia błędu oscyluje blisko zera przez większość okresu, co potwierdza, że ceny PZU zmieniają się powoli i model naiwny dobrze to wykorzystuje. Widoczny jest jeden wyraźny skok błędu w okolicach 17 września 2024 (ok. -10 zł). Okazuje się, że to był [dzień wypłat dywidend](#) dla tej spółki, czego model nie mógł przewidzieć.

2.2 Model ARIMA

2.3 Model VAR

2.4 Model MIDASR (A)

2.5 Model MIDASR (B)

3 Wyniki

4 Wnioski i podsumowanie

Bibliografia

Główny Urząd Statystyczny. (2026). *Wskaźniki makroekonomiczne*. Bazy GUS. <https://bazydanych.nerw.stat.gov.pl/wskazniki-makroekonomiczne>

Spis rysunków

1	Wykres akcji spółki PZU	5
2	Produkt Krajowy Brutto Polski	6
3	Inflacja	7
4	Procentowa stopa bezrobocia	8
5	Model naiwny - predykcja vs rzeczywistość (zbiór testowy)	15